

ТЕОРЕМА БАЙЕСА

УСЛОВНАЯ ПЛОТНОСТЬ РАСПРЕДЕЛЕНИЯ

$$p(y|x) = \frac{p(x,y)}{p(x)}$$

$$p(y|x)p(x) = p(x,y) = p(x|y)p(y) \Rightarrow$$

Формула обращения условной плотности

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}$$

УСЛОВНАЯ ПЛОТНОСТЬ РАСПРЕДЕЛЕНИЯ

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}$$

$$\begin{aligned} 1 &= \int p(x|y) dx = \int \frac{p(y|x)p(x)}{p(y)} dx = \\ &= \frac{1}{p(y)} \int p(y|x)p(x) dx \end{aligned}$$


Отсюда $p(y) = \int p(y|x)p(x) dx$ —
маргинализация или правило
суммирования

ТЕОРЕМА БАЙЕСА


$$p(y|x) = \frac{p(x|y)p(y)}{\int p(x|y)p(y)dy}$$

$$\text{Posterior} = \frac{\text{Likelihood} \times \text{Prior}}{\text{Evidence}}$$

УСЛОВНОЕ И МАРГИНАЛЬНОЕ РАСПРЕДЕЛЕНИЯ




УСЛОВНОЕ И МАРГИНАЛЬНОЕ РАСПРЕДЕЛЕНИЯ



$$p(x) = \int p(x, y) dy = \int p(x|y)p(y) dy$$

УСЛОВНОЕ И МАРГИНАЛЬНОЕ РАСПРЕДЕЛЕНИЯ



$$p(x) = \int p(x, y) dy = \int p(x|y)p(y) dy$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

› Пусть $X = (x_1, \dots, x_n)$ — выборка из н.о.р.с.в. $x_i \sim p(x|\theta)$

› $p(x|\theta)$ — плотность распределения, известная с точностью до параметров θ

› Задача: оценить θ по выборке X

› Метод максимального правдоподобия:

$$\begin{aligned}\theta_{ML} &= \operatorname{argmax}_{\theta} p(X|\theta) = \operatorname{argmax}_{\theta} \prod_{i=1}^n p(x_i|\theta) = \\ &= \operatorname{argmax}_{\theta} \sum_{i=1}^n \log p(x_i, \theta)\end{aligned}$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

› Достоинства метода:

- ▶ Асимптотическая несмещённость, т.е.
 $\mathbb{E} \theta_{ML} = \theta_*$ при $n \gg 1$
- ▶ Состоятельность: $\theta_{ML} \rightarrow \theta_*$ при $n \rightarrow +\infty$
- ▶ Асимптотическая нормальность
- ▶ Эффективность

› Недостаток:

- ▶ Основные теоретические гарантии получены при $\frac{n}{d} \gg 1$, где d — размерность θ

РЕЗЮМЕ

- › Условное и безусловное распределения
- › Теорема Байеса
- › Метод максимального правдоподобия

БАЙЕСОВСКИЙ ПОДХОД К ТЕОРИИ ВЕРОЯТНОСТЕЙ

ЧАСТОТНЫЙ И БАЙЕСОВСКИЙ ПОДХОДЫ

	Частотный	Байесовский
Интерпертация случайности	Объективная неопределённость	Субъективное незнание
Метод вывода	Метод максимального правдоподобия	Теорема Байеса
Оценки	θ_{ML}	$p(\theta X)$
Применимость	$\frac{n}{d} \gg 1$	$\forall n$

ИЛЛЮСТРАТИВНЫЙ ПРИМЕР

- › Имеется несколько косвенных проявлений y_1, \dots, y_m неизвестной величины x
- › Для каждой из них существует вероятностная модель, определяющая вероятность наблюдения того или иного значения $y_j : p_j(y_j|x)$
- › Задача: оценить x путём объединения информации о всех y_1, \dots, y_m

ИЛЛЮСТРАТИВНЫЙ ПРИМЕР

- › Фиксируем исходные представления о возможных значениях x в виде $p(x)$
- › Выполняем байесовский вывод относительно y_1 :

$$p(x|y_1) = \frac{p_1(y_1|x)p(x)}{\int p_1(y_1|x)p(x)dx}$$

ИЛЛЮСТРАТИВНЫЙ ПРИМЕР

- › Выполняем байесовский вывод относительно y_2 , используя результат предыдущего шага в качестве нового априорного распределения:


$$p(x|y_1, y_2) = \frac{p_2(y_2|x)p(x|y_1)}{\int p_2(y_2|x)p(x|y_1)dx}$$

› ...

- › Считаем $p(x|y_1, \dots, y_m) =$

$$= \frac{p_m(y_m|x)p(x|y_1, \dots, y_{m-1})}{\int p_m(y_m|x)p(x|y_1, \dots, y_{m-1})dx}$$

ИЛЛЮСТРАТИВНЫЙ ПРИМЕР



РЕЗЮМЕ

- › Байесовский подход к теории вероятностей
- › Объединение нескольких вероятностных моделей в более сложную модель

БАЙЕСОВСКИЕ МОДЕЛИ В ЗАДАЧАХ МАШИННОГО ОБУЧЕНИЯ

БАЙЕСОВСКИЙ ПОДХОД

- » При использовании подхода нам необходимо задать совместное распределение на все переменные, которые мы хотим предсказывать на этапах обучения или тестирования

ПРИМЕР: ЛИНЕЙНАЯ РЕГРЕССИЯ

› Рассмотрим задачу линейной регрессии:

$$x \in \mathbb{R}^d, w \in \mathbb{R}^d, t \in \mathbb{R}$$

› Три группы переменных:

- ▶ x — признаки
- ▶ t — целевая переменная
- ▶ w — веса линейной регрессии

› Вероятностная модель:

$$\begin{aligned} p(t, w | x) &= p(t | x, w) p(w) = \\ &= \mathcal{N}(t | w^T x, \sigma^2) \mathcal{N}(w | 0, I) \end{aligned}$$

ПРИМЕР: ЛИНЕЙНАЯ РЕГРЕССИЯ

› Пусть задана обучающая выборка

$$(X, T) = (x_i, t_i)_{i=1}^n,$$

тогда

ПРИМЕР: ЛИНЕЙНАЯ РЕГРЕССИЯ

$$\begin{aligned} w_{MP} &= \operatorname{argmax}_w p(w | X, T) = \operatorname{argmax}_w p(T | X, w) p(w) = \\ &= \operatorname{argmax}_w \prod_{i=1}^n p(t_i | x_i, w) p(w) = \\ &= \operatorname{argmax}_w \left[\sum_{i=1}^n \log p(t_i | x_i, w) + \log p(w) \right] = \\ &= \operatorname{argmin}_w \frac{1}{2\sigma^2} \sum_{i=1}^n (t_i - x_i^T w)^2 + \frac{1}{2} \|w\|^2 = \\ &= \operatorname{argmin}_w \left[\sum_{i=1}^n (t_i - x_i^T w)^2 + \sigma^2 \|w\|^2 \right] \end{aligned}$$

Поиск максимума апостериорной плотности эквивалентен МНК с L_2 -регуляризатором

ЗАЧЕМ НУЖНЫ БАЙЕСОВСКИЕ МЕТОДЫ?

- › Возможность строить сложные модели из простых путём использования выходов (апостериорного распределения) одной модели в качестве входов (априорного распределения) в другой

ЗАЧЕМ НУЖНЫ БАЙЕСОВСКИЕ МЕТОДЫ?

- › Возможность обработки последовательно поступающих данных “на лету” без необходимости повторного обучения с нуля

ЗАЧЕМ НУЖНЫ БАЙЕСОВСКИЕ МЕТОДЫ?

- › Возможность вводить настраиваемые параметры априорные распределения, которые:
 - ▶ отражают наши предпочтения о значениях параметров
 - ▶ предотвращают переобучение

ЗАЧЕМ НУЖНЫ БАЙЕСОВСКИЕ МЕТОДЫ?

- › Возможность обучаться по не полностью размеченным , частично размеченным и неразмеченным обучающим выборкам

РЕЗЮМЕ

- › Применение байесовского метода к линейной регрессии
- › Преимущества байесовских методов